

R para Ciência dos Dados - II

Primeira Parte

João Lopes e Pedro Sousa

Dezembro 2025



Programa



Programa



- **Transformação dos dados**
- **Exploração dos dados**
- **Modelação**
- Relatórios e apresentações
- Comunicação



Programa



- **Transformação dos dados**

- Vetores numéricos
- Fatores
- Vetores lógicos

- **Exploração dos dados**

- Variação
- Valores em falta
- Covariação
- Padrões e Modelos

- **Modelação**


- Construir modelo simples
- Construir modelo com workflow()
- Construir vários modelos com workflow()



Recapitulação



» Esquema geral



H. Wickham M. Çetinkaya-Rundel & G. Grolemund (2023)

Dia 1 - Transformação



Dia 1 - Transformação



- **Vetores numéricos** → 09:30 - 11:00 e 11:15 - 12:30
 - Contagens (c/ exercícios)
 - Transformações numéricas (c/ exercícios)
 - Transformações genéricas (c/ exercícios)
 - Estatísticas descritivas (c/ exercícios)
- **Fatores** → 14:00 - 15:00
 - Operações básicas
 - Base de dados gss_cat (c/ exercícios)
 - Alterar ordem dos fatores (c/exercícios)
 - Alterar os fatores (c/ exercícios)
- **Vetores lógicos** → 15:15 - 17:00
 - Comparações (c/ exercícios)
 - Álgebra booleana (c/ exercícios)
 - Sumarização (c/ exercícios)
 - Transformações condicionais (c/ exercícios)



Recapitulação



» Pacote **dplyr**

- `filter()` Selecionar linhas (i.e. observações);
- `arrange()` Ordenar linhas (i.e. observações);
- `select()` Selecionar colunas (i.e. variáveis);
- `mutate()` Criar novas colunas (i.e. variáveis);
- `summarize()` Calcular estatísticas descritivas.
- `group_by()` Criar grupos de observações para manipulação.

<https://dplyr.tidyverse.org/reference/index.html>

<https://rstudio.github.io/cheatsheets/html/data-transformation.html>



Recapitulação



» Pacote dplyr

```
library("tidyverse")

?diamonds

diamonds |>
  select(price, carat, cut) |>
  filter(carat < 3) |>
  mutate(lprice = log10(price)) |>
  group_by(cut) |>
  summarize(
    mean_lprice = mean(lprice)
    mean_carat = mean(carat)
  ) |>
  arrange(desc(mean_price))

#use data "diamonds"
#select "price", "carat" and "cut"
#filter for smaller diamonds
#create variable "lprice"
#group by "cut"
#calculate mean of "lprice"
#calculate mean of "carat"
#arrange by "mean_lprice"
```

Recapitulação



» Pacote dplyer

```
# A tibble: 5 × 3
  cut      mean_lprice mean_carat
<ord>      <dbl>      <dbl>
1 Fair          3.51          1.03
2 Premium        3.45          0.889
3 Good           3.41          0.847
4 Very Good      3.39          0.806
5 Ideal          3.32          0.702
```

Dia 2 - Exploração



Dia 2 - Exploração



- **Variação** → 09:30 - 11:00
 - Valores típicos (c/ exercícios)
 - Valores invulgares
- **Valores em falta** → 11:15 - 12:30
 - Explícitos (c/ exercícios)
 - Implícitos (c/ exercícios)
 - Fatores e grupos vazios
- **Covariação** → 14:00 - 16:00
 - Uma categórica e uma numérica (c/ exercícios)
 - Duas categóricas (c/ exercícios)
 - Duas numéricas (c/ exercícios)
- **Padrões e modelos** → 16:15 - 17:00

Recapitulação



» Pacote `ggplot2`

- Data;
- Aesthetic mapping (`aes`);
- Geometric object (`geom`);
- Statistical transformation (`stat`);
- Scale;
- Themes.

<https://ggplot2.tidyverse.org/reference/index.html>

<https://rstudio.github.io/cheatsheets/html/data-visualization.html>



Recapitulação



» Pacote ggplot2

```
set.seed(1984)


diamonds |>
  filter(carat < 3) |>
  slice_sample(n = 500, by = cut) |>
  ggplot(aes(x = carat, y = price, color = cut)) +
  geom_point(alpha = 0.1, size = 1) +
  stat_smooth(
    method = "lm",
    formula = "y ~ x + I(x^2) + I(x^3)",
    se = FALSE) +
  scale_x_continuous(trans = "log10") +
  scale_y_continuous(trans = "log10") +
  labs(x = "Weight", y = "Price", color = "Cut") +
  theme_minimal()
```

#use data "diamonds"
#filter for smaller diamonds
#sample for 500 obs per "cut"
#aesthetics mapping
#geometric object
#statistical transformation
#scale for x-axis
#scale for y-axis
#scale for labels
#change theme

Recapitulação



» Pacote ggplot2



Dia 3 - Modelação



Dia 3 - Modelação



- **Construir modelo simples** → 09:30 - 11:00
 - Explorar dados
 - Ajustar modelo (c/ exercícios)
 - Usar modelo para previsão (c/ exercícios)
- **Construir modelo com *workflow*** → 11:15 - 12:30
 - Explorar dados
 - Dividir dados
 - Criar *workflow* (c/ exercícios)
 - Ajustar modelo (c/ exercícios)
 - Avaliar modelo (c/ exercícios)
- **Construir vários modelos com *workflow*** → 14:00 - 15:00 e 15:15 - 17:00
 - Explorar dados
 - Dividir dados
 - Criar *workflow* e ajustar modelo 1 (c/ exercícios)
 - Criar *workflow* e ajustar modelo 2 (c/ exercícios)
 - Avaliar o melhor modelo (c/ exercícios)



Recapitulação



» Pacote `stats`: funções `lm()` e `summary()`

- Data;
- Formula (e.g. `formula()`);
- Fit model (eg. `lm()`, `glm()`, `aov()`, ...);
- Extract parameters (eg. `residuals()`, `predicted()`, `coef()`, ...);
- Testing assumptions (eg. `plot()`, ...);
- Evaluate model (eg. `summary()`, `AIC()`, `logLik()`, ...).

<https://www.datacamp.com/tutorial/linear-regression-R>

<https://rpubs.com/abigailpayne/743827>



Recapitulação



» Pacote `stats`: funções `lm()` e `summary()`

```
diamonds2 <- diamonds |> #use data "diamonds"
  filter(
    (x > 0) & (y > 0 & y < 20) & (z > 0 & z < 10), #filter out outliers
    carat < 3) |> #filter in smaller diamonds
  slice_sample(n = 1000) |> #sample for 1000 observations
  select(price, carat, cut) |> #select "price", "carat" and "cut"
  mutate(
    lprice = log10(price), #create variable "lprice"
    lcarat = log10(carat), #create variable "lcarat"
    fct_cut = factor(cut, ordered = FALSE)) #make variable "cut" into factor

mod1 <- formula("lprice ~ lcarat + fct_cut") #specify model
res1 <- lm(mod1, data = diamonds2) #fit model to data

summary(res1) #get summary
```

Recapitulação



» Pacote `stats`: funções `lm()` e `summary()`

Residuals:

Min	1Q	Median	3Q	Max
-0.33696	-0.06961	0.00255	0.07358	0.36898

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	3.56450	0.02020	176.449	< 2e-16	***
lcarat	1.70134	0.01384	122.938	< 2e-16	***
fct_cutGood	0.07818	0.02347	3.331	0.000896	***
fct_cutVery Good	0.09259	0.02164	4.279	2.06e-05	***
fct_cutPremium	0.08857	0.02144	4.131	3.91e-05	***
fct_cutIdeal	0.12437	0.02111	5.891	5.24e-09	***

Multiple R-squared: 0.9396, Adjusted R-squared: 0.9393

F-statistic: 3093 on 5 and 994 DF, p-value: < 2.2e-16

Recapitulação



» Pacote **performance**

- MLR.1 O modelo é linear nos parâmetros;
- MLR.2 Amostra aleatória (e.g. não há outliers, valores omissos aleatórios);
- MLR.3 Não há multicolinearidade entre preditores;
- MLR.4 Erro com valor esperado zero dado qualquer valor dos preditores;
- MLR.5 Erro com variância constante dado qualquer valor dos preditores;
- MLR.6 Erro é independente dos preditores e tem distribuição normal.

Wooldridge J, Introductory Econometrics: A Modern Approach, 7 ed. Thomson



Recapitulação



» Pacote performance

```
library("performance")

check_model(res1, check = c(
  #MLR.1 The population model is linear in the parameters
  "linearity",
  #MLR.3 No multicollinearity between predictors
  "vif",
  #MLR.5 The error has constant variance given any values of the parameters
  "homogeneity",
  #MLR.6 The error is independent of the predictors and is normally distributed
  "qq"
))
```


Recapitulação



» Pacote performance


Linearity

Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal



Collinearity


High collinearity (VIF) may inflate parameter uncer



Low (< 5)

Normality of Residuals

Dots should fall along the line





» Regressão linear simples


```
beta0 <- -1.6
beta1 <- 0.03
tb_lm <- tibble(
  x = runif(20, min = 18, max = 60),
  y = beta0 + beta1*x + rnorm(20, mean = 0, sd = 0.1)
)

res_lm <- lm(y ~ x, data = tb_lm)

tb_lm |>
  mutate(preds = predict(res_lm), resid = residuals(res_lm)) |>
  ggplot(aes(x = x, y = y)) + geom_point() +
  stat_smooth(method = "lm", formula = "y ~ x", se = FALSE, color = "blue") +
  geom_segment(aes(xend = x, yend = preds), color = "red")
```




» Regressão linear simples






» Regressão linear múltipla

```
beta0 <- -1.6; beta1 <- 0.03; beta2 <- 0.6
tb_lm2 <- tibble(
  x1 = runif(20, min = 18, max = 60),
  x2 = rbinom(20, size = 1, prob = 0.5),
  y = beta0 + beta1*x1 + (beta0 + beta2)*x2 + rnorm(20, mean = 0, sd = 0.1)
) |>
  mutate(x2 = factor(x2))
res_lm2 <- lm(y ~ x1 + x2, data = tb_lm2)
v1 <- res_lm2$coef
tb_lm2 |>
  mutate(preds = predict(res_lm2), resid = residuals(res_lm2)) |>
  ggplot(aes(x = x1, y = y, color = x2)) + geom_point() +
  geom_abline(slope = v1[2], intercept = v1[1], color = "#F8766D") +
  geom_abline(slope = v1[2], intercept = sum(v1[c(1, 3)]), color = "#00BFC4") +
  geom_segment(aes(xend = x1, yend = preds), color = "red")
```



» Regressão linear múltipla






» Regressão logística

```
beta0 <- -1.6
beta1 <- 0.03
tb_glm <- tibble(
  x = runif(20, min = 18, max = 60),
  pi_x = exp(beta0 + beta1*x) / (1 + exp(beta0 + beta1*x)),
  y = rbinom(20, size = 1, prob = pi_x)
)
res_glm <- glm(y ~ x, binomial(link="logit"), data = tb_glm)
tb_glm |>
  mutate(preds = predict(res_glm, type="resp"), resid = residuals(res_glm)) |>
  ggplot(aes(x = x, y = y)) + geom_point() +
  stat_smooth(method = "glm", formula = "y ~ x", se = FALSE, color = "blue",
    method.args = list(family = "binomial")) +
  geom_segment(aes(xend = x, yend = preds), color = "red") +
  geom_hline(yintercept = 0.5, linetype = "dashed", color = "gray")
```



» Regressão logística





» Árvores de decisão

```
library("rpart")


tb_rf <- tibble(
  x1 = ceiling(runif(20, min = 0, max = 4)),
  x2 = ceiling(runif(20, min = 0, max = 3)),
  x3 = ceiling(runif(20, min = 0, max = 3)),
  x = x1 - x2 - x3,
  pi_x = exp(x) / (1 + exp(x)),
  y = rbinom(20, size = 1, prob = pi_x)
) |> mutate(across(c(x1:x3, y), as.factor))

res_rd <- rpart(y ~ x1 + x2 + x3, data = tb_rf, method = "class",
  control = rpart.control(minsplit = 5))

plot(res_rd, branch = 0, margin = 0.02, branch.lwd = 2, branch.col = "blue")
text(res_rd, minlength = 2, use.n = TRUE, fancy = TRUE, fwidth = 1.5,
  fheight = 1, cex = 0.8, font = 2)
```




» Árvores de decisão



Avaliação de modelos




» Visão Geral



Avaliação de modelos




» Visão Geral



Avaliação de modelos



» Visão Geral



Avaliação de modelos



» Métricas: variável contínua

Root Mean Square Error (RMSE)

$$\text{RMSE} = \sqrt{\sum_{i=1}^n (\hat{y} - y)^2 / n}$$

Mean Absolute Error (MAE)

$$\text{MAE} = \sum_{i=1}^n |\hat{y} - y| / n$$

» Métricas: variável categórica (binária)

True Positive Rate (Sensitivity)

$$= \text{TP} / \text{P}$$

False Positive Rate (1 - Specificity)

$$= \text{FP} / \text{N} = 1 - \text{TN} / \text{N}$$

		Predicted (p = 0.50)	
		Positive	Negative
Real	Positive	True P.	False N.
	Negative	False P.	True N.

Avaliação de modelos


» Curva de ROC (Receiver Operating Characteristics)

Trade-off:

Sensitivity vs. Specificity

True Positive Rate (Sensitivity)
= TP/P

False Positive Rate (1 - Specificity)
= $FP/N = 1 - TN/N$



M. Thoma (2018)

Informações finais



Informações finais



» Gestão de projectos


- Estrutura de pastas;
- Ficheiro README (e nomeação de ficheiros);
- Controlo de versões (e.g. github.com, git.ine.pt).



Informações finais



» Estrutura de pastas



```
C:.\n├── Projects\n│   ├── 2023\n│   │   ├── 2023.01.01_ProjectName\n│   │   └── 2023.04.01_ProjectName\n│   ├── 2024\n│   │   ├── 2024.02.29_ProjectName\n│   │   └── 2024.12.25_ProjectName\n│   └── 2025\n│       ├── 2025.03.05_ProjectName\n│       └── 2025.10.31_DSR2025\n│           ├── bin\n│           ├── data\n│           ├── docs\n│           ├── media\n│           ├── results\n│           │   ├── 1.transform\n│           │   ├── 2.exploratory\n│           │   └── 3.modeling
```

Informações finais



» Ficheiro README

```
#autor:      Joao Sollari Lopes
#local:      INE, Lisboa
#criado:     28.08.2025
#modificado: 13.12.2025

+bin
  |0.examples.r          #exemplos para recapitulacao
  |0.install_packages.r  #instalar pacotes necessarios
  |1.transform.r          #transformacao de dados
  |2.exploration.r        #exploração de dados
  |3.modelling.r          #modelacao de dados

+docs
  |DSR-II2025_program.pdf #programa
  |DSR-II2025_slides.pdf  #slides [versao final]
  |DSR-II2025_slides_20250828.pptx #slides [v2025-08-28]
  |DSR-II2025_slides_20251213.pptx #slides [v2025-12-13]

+results
  +1.tranform            #resultados de "1.transform.r"
  +2.exploration          #resultados de "2.exploration.r"
  +3.modelling            #resultados de "3.modelling.r"
README.txt               #Este ficheiro
```


Informações finais



» Controlo de versões

bin/3.modelling.r							
@@ -2,7 +2,7 @@							
2	#local:	INE, Lisboa		2	#local:	INE, Lisboa	
3	#Rversion:	4.3.1		3	#Rversion:	4.3.1	
4	#criado:	17.07.2023		4	#criado:	17.07.2023	
5	- #modificado:	18.04.2024		5	+ #modificado:	16.09.2024	
6				6			
7	# 0. INDEX			7	# 0. INDEX		
8	{			8	{		
@@ -344,7 +344,7 @@ lr_res >							
344	scale_x_log10(labels = scales::label_number())			344	scale_x_log10(labels = scales::label_number())		
345				345			
346	lr_res >			346	lr_res >		
347	- show_best("roc_auc", n = 5) >			347	+ show_best(metric = "roc_auc", n = 5) >		
348	arrange(penalty)			348	arrange(penalty)		
349				349			
350	lr_best <-			350	lr_best <-		

Informações finais



» Comunidade R

- <https://www.r-project.org/>
- <https://www.tidyverse.org/>
- <https://www.tidymodels.org/>
- <https://education.rstudio.com/learn/>
- <https://www.r-project.org/help.html>
- <https://hour.ine.pt/>



Informações finais



» Bibliografia

» Wickham H & Grolemund G (2017) R for Data Science. O'Reilly Media Inc., Sebastopol.

URL: <https://r4ds.had.co.nz/>

» Wickham H, Çetinkaya-Rundel M & Grolemund G (2023) R for Data Science. O'Reilly Media Inc., Sebastopol. O'Reilly Media Inc., Sebastopol.

URL: <https://r4ds.hadley.nz/>

