



INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

Data Science com R - II

Primeira Parte

Pedro Sousa e João Lopes

Dezembro 2025





INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

Programa





INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

Programa



- **Transformação dos dados**
- **Exploração dos dados**
- **Modelação**
- Relatórios e apresentações
- Comunicação





Programa




- **Transformação dos dados**
 - Vetores numéricos
 - Fatores
 - Vetores lógicos
- **Exploração dos dados**
 - Variação
 - Valores em falta
 - Covariação
 - Padrões e Modelos
- **Modelação**
 - Construir modelo simples
 - Construir modelo com workflow()
 - Construir vários modelos com workflow()



Recapitulação



» Esquema geral



H. Wickham M. Çetinkaya-Rundel & G. Grolemund (2023)

Dia 1 - Transformação





Dia 1 - Transformação



- **Vetores numéricos** → 09:30 - 11:00 e 11:15 - 12:30
 - Contagens (c/ exercícios)
 - Transformações numéricas (c/ exercícios)
 - Transformações genéricas (c/ exercícios)
 - Estatísticas descritivas (c/ exercícios)
- **Fatores** → 14:00 - 15:00
 - Operações básicas
 - Base de dados gss_cat (c/ exercícios)
 - Alterar ordem dos fatores (c/exercícios)
 - Alterar os fatores (c/ exercícios)
- **Vetores lógicos** → 15:15 - 17:00
 - Comparações (c/ exercícios)
 - Álgebra booleana (c/ exercícios)
 - Sumarização (c/ exercícios)
 - Transformações condicionais (c/ exercícios)



Recapitulação



» Pacote **dplyr**

- `filter()` Selecionar linhas (i.e. observações);
- `arrange()` Ordenar linhas (i.e. observações);
- `select()` Selecionar colunas (i.e. variáveis);
- `mutate()` Criar novas colunas (i.e. variáveis);
- `summarize()` Calcular estatísticas descritivas.
- `group_by()` Criar grupos de observações para manipulação.

<https://dplyr.tidyverse.org/reference/index.html>

<https://rstudio.github.io/cheatsheets/html/data-transformation.html>





» Pacote dplyr

```
library("tidyverse")

?diamonds

diamonds |>
  select(price, carat, cut) |>
  filter(carat < 3) |>
  mutate(lprice = log10(price)) |>
  group_by(cut) |>
  summarize(
    mean_lprice = mean(lprice)
    mean_carat = mean(carat)
  ) |>
  arrange(desc(mean_price))
```

#use data "diamonds"
#select "price", "carat" and "cut"
#filter for smaller diamonds
#create variable "lprice"
#group by "cut"

#calculate mean of "lprice"
#calculate mean of "carat"

#arrange by "mean_lprice"



Recapitulação



» Pacote dplyr

```
# A tibble: 5 × 3
  cut      mean_lprice mean_carat
<ord>      <dbl>      <dbl>
1 Fair          3.51          1.03
2 Premium        3.45          0.889
3 Good           3.41          0.847
4 Very Good      3.39          0.806
5 Ideal          3.32          0.702
```

Dia 2 - Exploração





Dia 2 - Exploração



- **Variação** → 09:30 - 11:00
 - Valores típicos (c/ exercícios)
 - Valores invulgares
- **Valores em falta** → 11:15 - 12:30
 - Explícitos (c/ exercícios)
 - Implícitos (c/ exercícios)
 - Fatores e grupos vazios
- **Covariação** → 14:00 - 16:00
 - Uma categórica e uma numérica (c/ exercícios)
 - Duas categóricas (c/ exercícios)
 - Duas numéricas (c/ exercícios)
- **Padrões e modelos** → 16:15 - 17:00



Recapitulação



» Pacote **ggplot2**

- Data;
- Aesthetic mapping (**aes**);
- Geometric object (**geom**);
- Statistical transformation (**stat**);
- Scale;
- Themes.

<https://ggplot2.tidyverse.org/reference/index.html>

<https://rstudio.github.io/cheatsheets/html/data-visualization.html>



Recapitulação



» Pacote ggplot2

```
set.seed(1984)


diamonds |>
  filter(carat < 3) |>
  slice_sample(n = 500, by = cut) |>
  ggplot(aes(x = carat, y = price, color = cut)) +
  geom_point(alpha = 0.1, size = 1) +
  stat_smooth(
    method = "lm",
    formula = "y ~ x + I(x^2) + I(x^3)",
    se = FALSE) +
  scale_x_continuous(trans = "log10") +
  scale_y_continuous(trans = "log10") +
  labs(x = "Weight", y = "Price", color = "Cut") +
  theme_minimal()
```

#use data "diamonds"
#filter for smaller diamonds
#sample for 500 obs per "cut"
#aesthetics mapping
#geometric object
#statistical transformation
#scale for x-axis
#scale for y-axis
#scale for labels
#change theme

Recapitulação



» Pacote ggplot2





INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

Dia 3 - Modelação





Dia 3 - Modelação



- **Construir modelo simples** → 09:30 - 11:00
 - Explorar dados
 - Ajustar modelo (c/ exercícios)
 - Usar modelo para previsão (c/ exercícios)
- **Construir modelo com *workflow*** → 11:15 - 12:30
 - Explorar dados
 - Dividir dados
 - Criar *workflow* (c/ exercícios)
 - Ajustar modelo (c/ exercícios)
 - Avaliar modelo (c/ exercícios)
- **Construir vários modelos com *workflow*** → 14:00 - 15:00 e 15:15 - 17:00
 - Explorar dados
 - Dividir dados
 - Criar *workflow* e ajustar modelo 1 (c/ exercícios)
 - Criar *workflow* e ajustar modelo 2 (c/ exercícios)
 - Avaliar o melhor modelo (c/ exercícios)



Recapitulação



» Pacote `stats`: funções `lm()` e `summary()`

- Data;
- Formula (e.g. `formula()`);
- Fit model (eg. `lm()`, `glm()`, `aov()`, ...);
- Extract parameters (eg. `residuals()`, `predicted()`, `coef()`, ...);
- Testing assumptions (eg. `plot()`, ...);
- Evaluate model (eg. `summary()`, `AIC()`, `logLik()`, ...).

<https://www.datacamp.com/tutorial/linear-regression-R>

<https://rpubs.com/abigailpayne/743827>



Recapitulação



» Pacote `stats`: funções `lm()` e `summary()`

```
diamonds2 <- diamonds |>                                #use data "diamonds"
  filter(
    (x > 0) & (y > 0 & y < 20) & (z > 0 & z < 10), #filter out outliers
    carat < 3) |>                                         #filter in smaller diamonds
  slice_sample(n = 1000) |>                             #sample for 1000 observations
  select(price, carat, cut) |>                           #select "price", "carat" and "cut"
  mutate(
    lprice = log10(price),                               #create variable "lprice"
    lcarat = log10(carat),                               #create variable "lcarat"
    fct_cut = factor(cut, ordered = FALSE))              #make variable "cut" into factor

mod1 <- formula("lprice ~ lcarat + fct_cut")             #specify model
res1 <- lm(mod1, data = diamonds2)                      #fit model to data

summary(res1)                                           #get summary
```

Recapitulação



» Pacote `stats`: funções `lm()` e `summary()`

Residuals:

Min	1Q	Median	3Q	Max
-0.33696	-0.06961	0.00255	0.07358	0.36898

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	3.56450	0.02020	176.449	< 2e-16	***
lcarat	1.70134	0.01384	122.938	< 2e-16	***
fct_cutGood	0.07818	0.02347	3.331	0.000896	***
fct_cutVery Good	0.09259	0.02164	4.279	2.06e-05	***
fct_cutPremium	0.08857	0.02144	4.131	3.91e-05	***
fct_cutIdeal	0.12437	0.02111	5.891	5.24e-09	***

Multiple R-squared: 0.9396, Adjusted R-squared: 0.9393

F-statistic: 3093 on 5 and 994 DF, p-value: < 2.2e-16

Recapitulação



» Pacote **performance**

MLR.1 O modelo é linear nos parâmetros;

MLR.2 Amostra aleatória (e.g. não há outliers, valores omissos aleatórios);

MLR.3 Não há multicolinearidade entre preditores;

MLR.4 Erro com valor esperado zero dado qualquer valor dos preditores;

MLR.5 Erro com variância constante dado qualquer valor dos preditores;

MLR.6 Erro é independente dos preditores e tem distribuição normal.

Wooldridge J, Introductory Econometrics: A Modern Approach, 7 ed. Thomson



» Pacote performance

```
library("performance")

check_model(res1, check = c(
  #MLR.1 The population model is linear in the parameters
  "linearity",
  #MLR.3 No multicollinearity between predictors
  "vif",
  #MLR.5 The error has constant variance given any values of the parameters
  "homogeneity",
  #MLR.6 The error is independent of the predictors and is normally distributed
  "qq"
))
```


Recapitulação



» Pacote performance


Linearity

Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal




Collinearity

High collinearity (VIF) may inflate parameter uncertainty



Normality of Residuals

Dots should fall along the line



Low (< 5)



» Regressão linear simples


```
beta0 <- -1.6
beta1 <- 0.03
tb_lm <- tibble(
  x = runif(20, min = 18, max = 60),
  y = beta0 + beta1*x + rnorm(20, mean = 0, sd = 0.1)
)

res_lm <- lm(y ~ x, data = tb_lm)

tb_lm |>
  mutate(preds = predict(res_lm), resid = residuals(res_lm)) |>
  ggplot(aes(x = x, y = y)) + geom_point() +
  stat_smooth(method = "lm", formula = "y ~ x", se = FALSE, color = "blue") +
  geom_segment(aes(xend = x, yend = preds), color = "red")
```




» Regressão linear simples






» Regressão linear múltipla

```
beta0 <- -1.6; beta1 <- 0.03; beta2 <- 0.6
tb_lm2 <- tibble(
  x1 = runif(20, min = 18, max = 60),
  x2 = rbinom(20, size = 1, prob = 0.5),
  y = beta0 + beta1*x1 + (beta0 + beta2)*x2 + rnorm(20, mean = 0, sd = 0.1)
) |>
  mutate(x2 = factor(x2))
res_lm2 <- lm(y ~ x1 + x2, data = tb_lm2)
v1 <- res_lm2$coef
tb_lm2 |>
  mutate(preds = predict(res_lm2), resids = residuals(res_lm2)) |>
  ggplot(aes(x = x1, y = y, color = x2)) + geom_point() +
  geom_abline(slope = v1[2], intercept = v1[1], color = "#F8766D") +
  geom_abline(slope = v1[2], intercept = sum(v1[c(1, 3)]), color = "#00BFC4") +
  geom_segment(aes(xend = x1, yend = preds), color = "red")
```



» Regressão linear múltipla






» Regressão logística

```
beta0 <- -1.6
beta1 <- 0.03
tb_glm <- tibble(
  x = runif(20, min = 18, max = 60),
  pi_x = exp(beta0 + beta1*x) / (1 + exp(beta0 + beta1*x)),
  y = rbinom(20, size = 1, prob = pi_x)
)
res_glm <- glm(y ~ x, binomial(link="logit"), data = tb_glm)
tb_glm |>
  mutate(preds = predict(res_glm, type="resp"), resid = residuals(res_glm)) |>
  ggplot(aes(x = x, y = y)) + geom_point() +
  stat_smooth(method = "glm", formula = "y ~ x", se = FALSE, color = "blue",
    method.args = list(family = "binomial")) +
  geom_segment(aes(xend = x, yend = preds), color = "red") +
  geom_hline(yintercept = 0.5, linetype = "dashed", color = "gray")
```



» Regressão logística





» Árvores de decisão

```
library("rpart")


tb_rf <- tibble(
  x1 = ceiling(runif(20, min = 0, max = 4)),
  x2 = ceiling(runif(20, min = 0, max = 3)),
  x3 = ceiling(runif(20, min = 0, max = 3)),
  x = x1 - x2 - x3,
  pi_x = exp(x) / (1 + exp(x)),
  y = rbinom(20, size = 1, prob = pi_x)
) |> mutate(across(c(x1:x3, y), as.factor))

res_rd <- rpart(y ~ x1 + x2 + x3, data = tb_rf, method = "class",
  control = rpart.control(minsplit = 5))

plot(res_rd, branch = 0, margin = 0.02, branch.lwd = 2, branch.col = "blue")
text(res_rd, minlength = 2, use.n = TRUE, fancy = TRUE, fwidth = 1.5,
  fheight = 1, cex = 0.8, font = 2)
```




» Árvores de decisão



Avaliação de modelos




» Visão Geral



Avaliação de modelos




» Visão Geral



Avaliação de modelos



» Visão Geral



Avaliação de modelos



» Métricas: variável contínua

Root Mean Square Error (RMSE)

$$\text{RMSE} = \sqrt{\sum_{i=1}^n (\hat{y} - y)^2 / n}$$

Mean Absolute Error (MAE)

$$\text{MAE} = \sum_{i=1}^n |\hat{y} - y| / n$$

» Métricas: variável categórica (binária)

True Positive Rate (Sensitivity)

$$= \text{TP} / \text{P}$$

False Positive Rate (1 - Specificity)

$$= \text{FP} / \text{N} = 1 - \text{TN} / \text{N}$$

		Predicted (p = 0.50)		
Real		Positive	Negative	
Positive		True P.	False N.	P.
Negative		False P.	True N.	N.

Avaliação de modelos




» Curva de ROC (Receiver Operating Characteristics)

Trade-off:

Sensitivity vs. Specificity

True Positive Rate (Sensitivity)
= TP/P

False Positive Rate (1 - Specificity)
= $FP/N = 1 - TN/N$



M. Thoma (2018)



INSTITUTO NACIONAL DE ESTATÍSTICA
STATISTICS PORTUGAL

Informações finais



Informações finais



» Gestão de projectos


- Estrutura de pastas;
- Ficheiro README (e nomeação de ficheiros);
- Controlo de versões (e.g. github.com, git.ine.pt).



Informações finais



» Estrutura de pastas



```
C:.\n├── Projects\n│   ├── 2023\n│   │   ├── 2023.01.01_ProjectName\n│   │   └── 2023.04.01_ProjectName\n│   ├── 2024\n│   │   ├── 2024.02.29_ProjectName\n│   │   └── 2024.12.25_ProjectName\n│   └── 2025\n│       ├── 2025.03.05_ProjectName\n│       └── 2025.10.31_DSR2025\n│           ├── bin\n│           ├── data\n│           ├── docs\n│           ├── media\n│           ├── results\n│           │   ├── 1.transform\n│           │   ├── 2.exploratory\n│           │   └── 3.modeling
```

Informações finais



» Ficheiro README

```
#autor:      Joao Sollari Lopes
#local:      INE, Lisboa
#criado:     28.08.2025
#modificado: 13.12.2025

+bin
  |0.examples.r           #exemplos para recapitulacao
  |0.install_packages.r  #instalar pacotes necessarios
  |1.transform.r          #transformacao de dados
  |2.exploration.r        #exploração de dados
  |3.modelling.r          #modelacao de dados

+docs
  |DSR-II2025_program.pdf #programa
  |DSR-II2025_slides.pdf  #slides [versao final]
  |DSR-II2025_slides_20250828.pptx #slides [v2025-08-28]
  |DSR-II2025_slides_20251213.pptx #slides [v2025-12-13]

+results
  +1.tranform             #resultados de "1.transform.r"
  +2.exploration          #resultados de "2.exploration.r"
  +3.modelling            #resultados de "3.modelling.r"
README.txt               #Este ficheiro
```


Informações finais



» Controlo de versões

bin/3.modelling.r							
@@ -2,7 +2,7 @@							
2	#local:	INE, Lisboa		2	#local:	INE, Lisboa	
3	#Rversion:	4.3.1		3	#Rversion:	4.3.1	
4	#criado:	17.07.2023		4	#criado:	17.07.2023	
5	- #modificado:	18.04.2024		5	+ #modificado:	16.09.2024	
6				6			
7	# 0. INDEX			7	# 0. INDEX		
8	{			8	{		
@@ -344,7 +344,7 @@ lr_res >							
344	scale_x_log10(labels = scales::label_number())			344	scale_x_log10(labels = scales::label_number())		
345				345			
346	lr_res >			346	lr_res >		
347	- show_best("roc_auc", n = 5) >			347	+ show_best(metric = "roc_auc", n = 5) >		
348	arrange(penalty)			348	arrange(penalty)		
349				349			
350	lr_best <-			350	lr_best <-		

Informações finais



» Comunidade R

- <https://www.r-project.org/>
- <https://www.tidyverse.org/>
- <https://www.tidymodels.org/>
- <https://education.rstudio.com/learn/>
- <https://www.r-project.org/help.html>
- <https://hour.ine.pt/>



Informações finais



» Bibliografia

» Wickham H & Grolemund G (2017) R for Data Science. O'Reilly Media Inc., Sebastopol.

URL: <https://r4ds.had.co.nz/>

» Wickham H, Çetinkaya-Rundel M & Grolemund G (2023) R for Data Science. O'Reilly Media Inc., Sebastopol. O'Reilly Media Inc., Sebastopol.

URL: <https://r4ds.hadley.nz/>

